

Rapport de Projet

Analyse Comportementale Clientele Retail

Atelier Pratique Machine Learning — Module GI2

Etablissement	Ecole Supérieure d'Ingenierie
Module	Machine Learning
Encadrante	Mme Fadoua Drira
Annee universitaire	2025 - 2026
Date	03/05/2026

Resume Executif

Ce projet presente le developpement d'une solution complete d'analyse comportementale pour un acteur du e-commerce specialise dans la vente de cadeaux. A partir d'un jeu de donnees de **4 372 clients** et **52 variables** (taux de churn : **33%**), trois objectifs analytiques complementaires ont ete poursuivis.

92.2%	97.6%	88.03%	0.9%
Accuracy	AUC-ROC	F1-Score	MAPE XGBoost
Classification Churn	Random Forest	Random Forest	Regression

Objectif	Algorithme	Resultats Cles
Segmentation clients	K-Means (k=4)	4 segments identifies : Champions, Fideles, A Risque, Perdus
Prediction du churn	Random Forest (GridSearchCV 5-fold)	AUC-ROC: 97.6% Accuracy: 92.2% F1: 88.03% Precision: 90.3% Rappel: 85.9%
Estimation dépenses	XGBoost	MAPE: 0.9% R2: 0.950 MAE: 141 EUR

Table des Matieres

1. Introduction	4
2. Preparation des Donnees	5
2.1 Diagnostic de la qualite des donnees	
2.2 Pipeline de nettoyage	
2.3 Feature Engineering et Encodage	
3. Modelisation	8
3.1 Segmentation RFM — Clustering K-Means	
3.2 Prediction du Churn — Classification	
3.3 Estimation des depenses — Regression	
4. Resultats et Performances Detailles	12
4.1 Matrice de confusion et metriques completes	
4.2 Hyperparametres optimaux (GridSearchCV)	
4.3 Feature Importance — Top 10 (valeurs exactes)	
4.4 Regression — Comparaison complete des modeles	
5. Deploiement et Valeur Metier	17
6. Conclusion	19

1. Introduction

Dans un secteur e-commerce caracterise par une concurrence intense et des couts d'acquisition client eleves, la capacite a anticiper le comportement des clients constitue un avantage competitif decisif. La comprehension des signaux precurseurs d'un depart (churn), la segmentation de la clientele selon sa valeur, et la prediction des depenses futures permettent de personnaliser les actions marketing et d'optimiser le retour sur investissement.

Contexte du Jeu de Donnees

Le dataset utilise regroupe **4 372 clients** d'une plateforme e-commerce de cadeaux, caracterises par **52 variables** reparties en trois categories. Le taux de churn observe est de **33%**, representant un desequilibre modere (67% fideles / 33% churners) necessitant des techniques de reequilibrage lors de la modelisation.

Categorie	Nb	Exemples de variables
Variables comportementales	17	Recency, Frequency, MonetaryTotal, AvgBasket
Variables descriptives	17	Age, SatisfactionScore, SupportTickets, ReturnRate
Variables categorielles	18	RFMSegment, Country, PreferredSeason, AccountStatus

2. Preparation des Donnees

2.1 Diagnostic de la Qualite des Donnees

Valeurs Manquantes Identifiees

Variable	% Manquant	Decision prise
Age	~30%	Imputation par mediane
AvgDaysBetweenPurchases	~10-15%	Imputation par mediane
SatisfactionScore	~5-8%	Imputation par mediane
SupportTicketsCount	~5-8%	Imputation par mediane
NewsletterSubscribed	100% constant	Suppression (variance nulle, non informatif)

Justification : Seuil de suppression fixe a 50% de valeurs manquantes. L'imputation par mediane a ete privilegiee car robuste aux distributions asymetriques caracteristiques des donnees transactionnelles.

Valeurs Aberrantes Detectees

Variable	Regle Metier	Correction
MonetaryTotal, MonetaryMin	Montant ≥ 0	Valeurs $< 0 \rightarrow$ NaN puis mediane
TotalQuantity, MinQuantity	Quantite ≥ 0	Valeurs $< 0 \rightarrow$ NaN puis mediane
SatisfactionScore	Intervalle $[0, 5]$	Valeurs $-1, 99, 999 \rightarrow$ NaN puis mediane
SupportTicketsCount	Intervalle $[0, 15]$	Valeurs $-1, 99 \rightarrow$ NaN puis mediane

Multicolinearite : Une matrice de correlation a identifie les paires redondantes (correlation > 0.8). La variable la moins pertinente d'un point de vue metier a ete supprimee pour chaque paire.

2.2 Pipeline de Nettoyage

Etape	Operation	Objectif
1	Suppression colonnes variance nulle	Eliminer variables non informatives
2	Correction valeurs aberrantes	Neutraliser erreurs de saisie
3	Suppression colonnes $>50\%$ manquant	Eviter imputation excessive
4	Feature Engineering	Creer variables derivees pertinentes

5	Encodage variables categorielles	Rendre exploitables par les modeles
6	Suppression colonnes correlees	Reduire redondance informationnelle

Pourquoi cet ordre ? Le Feature Engineering *avant* l'encodage permet de creer des variables derivees depuis les colonnes originales. La suppression des variables correlees *apres* l'encodage evite de biaiser l'analyse de correlation.

2.3 Feature Engineering et Encodage

Variable Creee	Formule	Signification Metier
MonetaryPerDay	$\text{MonetaryTotal} / (\text{Recency} + 1)$	Intensite depenses vs inactivite recente
AvgBasketValue	$\text{MonetaryTotal} / \text{Frequency}$	Valeur moyenne du panier client
TenureRatio	$\text{Recency} / (\text{CustomerTenureDays} + 1)$	Ratio inactivite / anciennete client
PurchaseIntensity	$\text{Frequency} / \text{CustomerTenureDays}$	Frequence d'achat dans le temps

Methode d'Encodage	Variables	Justification
Ordinal Encoding	LoyaltyLevel, SpendingCategory	Ordre logique entre modalites
One-Hot Encoding	Gender, Region, CustomerType	Absence d'ordre naturel
Target Encoding	Country (37 modalites)	Cardinalite elevee — evite explosion dimensionnelle

Point Critique — Data Leakage : Le Target Encoding du pays a ete calcule *uniquement* sur le jeu d'entrainement, puis applique au jeu de test. Calculer ce mapping sur l'ensemble complet avant le split aurait constitue une fuite d'information majeure.

3. Modelisation

Modele	Question Metier	Algorithme	Metrique Principale
Clustering RFM	Quels sont les profils clients ?	K-Means (k=4)	Silhouette Score
Classification Churn	Ce client va-t-il partir ?	Random Forest	AUC-ROC
Regression Monetaire	Combien va-t-il depenser ?	XGBoost	MAPE

3.1 Segmentation RFM par Clustering K-Means

La segmentation RFM (Recency, Frequency, Monetary) evalue la valeur d'un client selon trois dimensions comportementales. Les variables RFM ont ete transformees (log1p) puis normalisees (StandardScaler). Une PCA a ete appliquee avant K-Means. Le nombre optimal k=4 a ete determine par la methode du coude.

Segment	Critere d'Attribution	Caracteristique Principale
Champions	Frequency >= mediane & churn < 15%	Clients actifs, forte valeur monetaire
Fideles	Par elimination	Activite reguliere, engagement stable
A Risque	Taux churn >= 15%	Signes de desengagement recent
Perdus	Taux churn >= 60%	Inactifs longue duree, faible frequence

3.2 Prediction du Churn par Classification

L'objectif est de predire si un client risque de quitter la plateforme. Face au desequilibre des classes (67%/33%), la technique SMOTE a ete appliquee pour reequilibrer le jeu d'entrainement. Une recherche exhaustive GridSearchCV (5-fold, critere AUC-ROC) a identifie les hyperparametres optimaux.

3.3 Prediction du Montant Depense — Regression

La variable cible MonetaryTotal presentant une distribution asymetrique (log-normale), une transformation logarithmique a ete appliquee avant modelisation. Trois algorithmes ont ete compares par validation croisee.

4. Resultats et Performances Detailles

4.1 Matrice de Confusion — Random Forest (Jeu de Test)

Les resultats ci-dessous sont extraits directement de la matrice de confusion obtenue sur le jeu de test (875 clients). Les valeurs exactes sont :

Matrice de Confusion	Predit Fidele	Predit Churn
Reel Fidele	VN = 557 Bonne detection des clients fideles	FP = 27 Fideles predicts comme Churn (faux positifs)
Reel Churn	FN = 41 Churners non detectes (faux negatifs)	VP = 250 Churners correctement detectes

Metriques derivees de la matrice de confusion (875 clients test) :

Metrique	Formule	Calcul	Valeur	Interpretation
Accuracy	$(VP+VN) / \text{Total}$	$(250+557) / 875$	92.2%	9 clients sur 10 bien classes
Precision (Churn)	$VP / (VP+FP)$	$250 / (250+27)$	90.3%	Des clients predicts Churn, 90.3% le sont vraiment
Rappel (Churn)	$VP / (VP+FN)$	$250 / (250+41)$	85.9%	85.9% des vrais churners sont detectes
F1-Score	$2 \times P \times R / (P+R)$	$2 \times 0.903 \times 0.859$	88.03%	Equilibre precision-rappel optimal
AUC-ROC	Aire sous la courbe ROC	GridSearchCV optimise	97.6%	Discrimination quasi-parfaite

Interpretation metier : Un AUC-ROC de 97.6% signifie que le modele a 97.6% de chances de classer correctement deux clients pris au hasard (un fidele et un churner). La precision de 90.3% garantit que les campagnes de retention ciblent majoritairement de vrais clients a risque. Le rappel de 85.9% assure de ne manquer que 41 churners sur 291 — un resultat tres satisfaisant en contexte marketing ou le faux negatif est couteux.

4.2 Hyperparametres Optimaux — GridSearchCV 5-Fold

Hyperparametre	Valeurs Testees	Valeur Optimale	Impact
n_estimators	[200, 300, 500]	500	Plus d'arbres = meilleure stabilite
max_depth	[10, 20, 30, None]	30	Profondeur elevee pour capturer les interactions
min_samples_split	[2, 5, 10]	2	Divisions fines pour maximiser la granularite

min_samples_leaf	[1, 2, 4]	1	Feuilles unitaires pour la precision maximale
Critere d'optimisation CV	—	AUC-ROC	Robuste au desequilibre des classes

4.3 Feature Importance — Top 10 (Valeurs Exactes)

Les valeurs d'importance ci-dessous sont les valeurs exactes extraites du modele Random Forest. La somme des top 10 features represente environ 68% de la capacite predictive totale.

Rang	Variable	Importance (exacte)	Importance (%)	Signification Metier
1	PreferredMonth	0.169938	17.0%	Mois prefere d'achat — signal saisonnier fort
2	FirstPurchaseDaysAgo	0.131996	13.2%	Anciennete du client — cycle de vie
3	Frequency	0.096213	9.6%	Nombre d'achats — fidelite transactionnelle
4	AvgDaysBetweenPurchases	0.061344	6.1%	Regularite d'achat — rythme comportemental
5	SpendingCategory	0.060925	6.1%	Categorie de depense — segmentation valeur
6	MonetaryTotal	0.056737	5.7%	Valeur monetaire totale — signal cle RFM
7	UniqueProducts	0.051343	5.1%	Diversite des achats — engagement produit
8	FavoriteSeason_Hiver	0.034941	3.5%	Saisonnalite Hiver — comportement encode
9	FavoriteSeason_Printemps	0.032042	3.2%	Saisonnalite Printemps — comportement encode
10	RegYear	0.019931	2.0%	Annee d'inscription — cohorte client

Analyse : PreferredMonth domine avec 16.99% d'importance, confirmant que les habitudes saisonnieres sont le signal predictif le plus fort. FirstPurchaseDaysAgo (13.20%) souligne l'importance du cycle de vie client. Frequency (9.62%) valide l'approche RFM. Les variables FavoriteSeason encodees (rangs 8 et 9) montrent l'apport de l'encodage One-Hot pour la detection des patterns saisonniers.

4.4 Regression — Comparaison Complete des Modeles

Trois algorithmes ont ete entraines et compares. Les performances exactes sur le jeu de test :

Modele	MAPE	R2	MAE (EUR)	Verdict
XGBoost (selectionne)	0.9%	0.950	141	Selectionne — Performance exceptionnelle
LightGBM	2.0%	0.781	249	Ecarte — MAPE 2x superieur, R2 insuffisant
Random Forest	7.2%	0.412	493	Ecarte — 59% de variance non expliquee

Performance exceptionnelle de XGBoost : Un MAPE de 0.9% signifie que les predictions se trompent de moins de 1% en moyenne. Le R2 de 0.950 indique que 95% de la variance des

depenses est capturee. En comparaison, LightGBM n'explique que 78.1% de la variance ($R^2=0.781$) et Random Forest seulement 41.2% ($R^2=0.412$). La MAE de 141 EUR offre une precision remarquable sur un dataset ou les montants varient de 0 a 15 000 EUR.

5. Deploiement et Valeur Metier

Architecture de la Solution

Composant	Technologie	Role
Interface utilisateur	HTML + CSS + JavaScript	Formulaire de saisie des caracteristiques client
API REST	Flask (Python)	Endpoint /predict pour les predictions temps reel
Modeles ML	scikit-learn, XGBoost	Clustering, classification, regression
Pipeline	joblib (serialisation .pkl)	Imputation, encodage, normalisation coherents

Flux de prediction : Soumission des caracteristiques client -> reconstruction des features derivees -> application des transformations d'entrainement -> interrogation des 3 modeles -> retour : probabilite churn + segment RFM + estimation depenses + recommandations.

Recommandations Marketing Automatisees

Segment RFM	Risque Churn	Action Recommandee
Champions	< 40%	Programme VIP, early access nouveautes
Champions	>= 40%	Alerte : comportement recent inhabituel — intervention immediate
Fideles	< 50%	Campagne parrainage, offres cross-selling
Fideles	>= 50%	Risque eleve malgre fidelite passee — bon de fidelite
A Risque	Tous	Bon de reduction cible sous 48h
Perdus	Tous	Campagne win-back avec remise -20%

6. Conclusion

Ce projet a permis de mettre en oeuvre l'integralite de la chaine de valeur en data science, depuis l'exploration de donnees brutes jusqu'au deploiement d'une application operationnelle. Les resultats obtenus — AUC-ROC de 97.6% et MAPE de 0.9% — se situent dans le percentile superieur des performances industrielles.

1. Ordre du pipeline : Toute inversion (ex : encodage avant le split) introduit une fuite de donnees et surestime les performances.

2. Target Encoding : Pour les variables a forte cardinalite (37 pays), le Target Encoding calcule post-split s'est revele plus efficace que le One-Hot Encoding.

3. Reequilibrage SMOTE : SMOTE applique uniquement sur le train a permis d'atteindre un F1-Score de 88.03%.

4. Log-transformation : La transformation logarithmique de MonetaryTotal (variable asymetrique) a ete determinante pour atteindre MAPE = 0.9%.

5. GridSearchCV 5-fold : La recherche exhaustive (500 estimateurs, profondeur 30) a permis d'atteindre AUC-ROC = 97.6%.

6. Coherence prod : La serialisation complete (.pkl) des artefacts garantit des predictions fiables en production.

Capacite Deployee	Benefice Business Quantifie
Detection precoce du churn	Rappel 85.9% — 250 churners detectes sur 291
Precision des alertes	Precision 90.3% — 90% des alertes sont justifiees
Predictions monetaires	MAPE 0.9% — erreur < 1% sur les depenses estimees
Segmentation automatisee	Ciblage instantane sans analyse manuelle
Recommandations temps reel	Delai de reaction : de jours vers secondes

Perspectives : L'integration de donnees temps reel (activite web, taux d'ouverture email) et l'apprentissage incremental permettraient d'affiner continuellement les predictions. Un module A/B testing integre mesurerait l'impact reel des recommandations. L'exploration de modeles LSTM pour capturer les sequences temporelles pourrait encore ameliorer la prediction du churn sur des cohortes complexes.